

笔记

详情

返回 拿个 offer-开源&项目实战



马丁

2026-03-08 19:37

《AI大模型Ragent项目》——多轮对话记忆设计

到这里，RAG 系列的核心链路已经全部打通了：数据分块 → 元数据管理 → 向量化 → 向量数据库 → 检索策略 → 生成策略 → Function Call → MCP 协议。从数据准备到检索生成，再到工具调用，一条完整的链路。

但你把这套系统上线之后，用户很快就会给你提一个 bug：你们这个 AI 是不是没有记忆？场景是这样的：用户问“iPhone 1 ...

《AI大模型Ragent项目》——多轮对话记忆设计

最后编辑：2026-03-09 17:47



等 18 人觉得很赞



咖啡不加糖：相较于MySQL，用ES进行存储历史会话是不是也可以🤔，倒排索引还能加速查找速度

2026-03-19 08:50

雯ww63 回复 咖啡不加糖：用什么存储我觉得都OK。都能实现。但是我觉得拿场景来说，MYSQL就做存储、ES称之为搜索引擎，优势在于全文搜索、做召回的。这里我觉得场景是只是做存储，那mysql的成本和性价比肯定是比较合适的。你说的倒排索引增加查找速度、那其实回到性能上，我觉得不如用redis

2026-03-24 12:58

4

一切随缘 回复 咖啡不加糖：es 是搜索引擎，明白了吗，如果后续有搜索的需求，可以mysql es 都存一份

2026-05-28 16:36

咖啡不加糖 回复 一切随缘：我是这个意思哈哈，现在明白了，没有最好的技术，只有最好的故事😁

2026-05-29 18:47



Best: 打卡

2026-03-28 16:40

## 笔记



阳zero: 马哥, 这里实现的算是短期记忆吗, 长期记忆是不是跨会话的, 这里为什么不用实现呢

2026-04-10 21:33

新城 回复 阳zero: 感觉这个项目是以会话为单位的, 互相独立, 如果跨会话做长期记忆会导致上下文太过混乱, 像 openclaw 那种才需要跨会话长期记忆的功能吧

2026-04-11 17:55

1

一切随缘 回复 阳zero: 市面上现在的都是以一个会话作为一个记忆单元吧

2026-05-28 16:37